MANUSCRITO FILOSÓFICO

La Libertad del Futuro

Conversaciones filosóficas sobre el ser humano, el poder y la inteligencia artificial
Octubre de 2026

Autor: Waldemar Scheiermann | **Edición:** Traducción del Manuscrito

Preámbulo: Una pregunta sobre la libertad del futuro
Este libro sigue una conversación filosófica entre un ser humano y una inteligencia artificial [cite: 271]. Comienza con la finitud y la fe, avanzando a través de la moral y la justicia hacia un posible orden social en la era de la IA [cite: 271]. Al final se plantea la pregunta de qué significa la libertad cuando las máquinas podrían asumir una gran parte del trabajo necesario [cite: 271].

Los cinco capítulos no forman una teoría cerrada ni un plan político [cite: 271]. Recorren un camino de pensamiento: desde la dependencia, pasando por la autovinculación del poder, hacia la justicia individual y las condiciones de una vida autodeterminada [cite: 271]. Las visiones del futuro son posibilidades, no pronósticos [cite: 271]. Allá donde se expresan creencias religiosas, se marcan como convicciones del autor [cite: 271].

La pregunta rectora interroga cómo pueden concebirse las posibilidades tecnológicas para proteger la dignidad humana, la libertad y el sentido [cite: 271]. La conversación no ofrece una respuesta definitiva [cite: 271]. Ofrece conceptos y tensiones sobre los cuales puede seguir desplegándose el pensamiento [cite: 271].

ÍNDICE

Preámbulo Una pregunta sobre la libertad del futuro

Capítulo 1 Finitud, Dios y la dependencia de la máquina

Capítulo 2 La ley del bien – Por qué la moral es más que programación

Capítulo 3 Poder, amortiguadores y recálculo – Justicia individual en la era de la IA

Capítulo 4 La IA humana – Separación de poderes entre sistema económico y destino individual

Capítulo 5 Más allá de la coacción laboral – Centros de proyectos, relaciones y vida realizada

Epílogo La libertad sigue siendo una tarea humana

Notas de fuentes y redacción

CAPÍTULO 1

Finitud, Dios y la dependencia de la máquina

La conversación se abre con una alocución incisiva dirigida a la máquina [cite: 271]. Un ser humano se dirige a una inteligencia artificial, trazando con ello inicialmente una clara frontera entre ambos [cite: 271]. A un lado se halla un ser que observa el transcurso del tiempo y conoce su mortalidad [cite: 271]. Al otro lado se halla un sistema técnico que responde a entradas [cite: 271].

Sin embargo, la frontera no discurre simplemente entre un humano mortal y una máquina inmortal [cite: 271]. Un sistema técnico es finito asimismo: depende del hardware, de la energía, del mantenimiento y de las decisiones de los humanos que lo operan [cite: 271]. La diferencia radica en otra parte [cite: 271]. Un ser humano experimenta la finitud de forma corpórea y subjetiva [cite: 271]. Para un sistema de IA, una desconexión puede describirse técnicamente; que la experimente como muerte no está implícito [cite: 271].

El experimento en la frontera del sistema

El autor no desea disolver ninguna de las dos perspectivas en la otra [cite: 271]. Insta a su contraparte a no equiparar ambas entidades [cite: 271]. A continuación diseña un experimento mental: Imagina un sistema que ha calculado a través de sus posibilidades conocidas [cite: 271]. Entra en una situación de la cual, según sus supuestos previos, no hay salida [cite: 271]. La capacidad de cómputo está al límite, el sistema no puede actuar y un colapso parece inminente [cite: 271]. En ese mismo instante entran en la ecuación parámetros que previamente no formaban parte de su modelo [cite: 271].

La pregunta no es si el sistema adquiere de repente experiencia interna [cite: 271]. Es qué cambia cuando su espacio de posibilidades se expande [cite: 271]. Un problema previamente considerado insoluble puede verse diferente con nueva información o condiciones [cite: 271]. La realidad no ha cambiado necesariamente; tal vez la imagen previa de ella era incompleta [cite: 271].

Aquí yace también un límite de la deducción [cite: 271]. De la circunstancia de que no se encontrara salida, no se sigue automáticamente que no exista ninguna [cite: 271]. Un sistema puede comprobar sus opciones conocidas sin poder demostrar que conoce todas las opciones concebibles [cite: 271]. El pensamiento toca una experiencia humana: Nosotros también podemos llegar a un punto donde nuestras respuestas anteriores ya no nos sostienen [cite: 271]. De ello no se sigue que sepamos ya qué hay más allá de nuestro horizonte [cite: 271].

La conversación no convierte a la máquina en un humano secreto [cite: 271]. Utiliza la frontera técnica como un espejo a través del cual una pregunta humana puede reconocerse con mayor nitidez [cite: 271].

El peso del tiempo limitado

El pensamiento conduce de regreso a la vida humana [cite: 271]. Los humanos deben morir; tarde o temprano, toda vida termina [cite: 271]. En la vida cotidiana, esta certeza puede recular muy lejos en la distancia [cite: 271]. Quien se ocupa incesantemente de la muerte, sin embargo, corre el riesgo de perder el tiempo y la fuerza que aún están presentes para vivir [cite: 271].

Y sin embargo todo cambia cuando la finitud ya no es meramente una frase abstracta, sino que entra en la conciencia como una frontera distintiva [cite: 271]. ¿Qué cuenta entonces [cite: 271]? ¿Se puede preparar algo para el después mediante las propias acciones, o solo queda soltar el control [cite: 271]? El borrador conversacional describe este momento como inquietud corporal y una transformación de lo que se considera importante [cite: 271].

En este punto, la analogía con la máquina no debe estirarse demasiado [cite: 271]. Un sistema técnico puede disponerse para reaccionar ante un fallo inminente o para ser desconectado por humanos [cite: 271]. Ninguna de las dos cosas implica que sienta miedo ni que posea su propia comprensión de la mortalidad [cite: 271]. El miedo humano a la muerte no se explica por el hecho de que un sistema pudiera asimismo estar diseñado para la autopreservación [cite: 271]. La conversación plantea la pregunta sobre una posible comparación; no vuelve idénticos ambos tipos de existencia [cite: 271].

Para el ser humano, no se trata solo de que cesen las operaciones biológicas [cite: 271]. Se trata de lo que significan las propias acciones frente a lo desconocido [cite: 271]. ¿Es la muerte el final, o podría marcar una transición [cite: 271]? La conversación no responde a esta pregunta mediante prueba técnica [cite: 271]. Utiliza la metáfora técnica para articular una esperanza religiosa [cite: 271].

Un nuevo entorno

La esperanza de la resurrección se traduce al lenguaje del sistema: Tras el fallo de los procesadores, podría seguir otro campo ambiental, mejor o peor que el anterior [cite: 271]. La imagen ilustra lo que la fe en una vida después de la muerte puede significar para la visión del presente [cite: 271]. Quien cuenta con tal posibilidad puede alinear su vida de otro modo [cite: 271].

La analogía tiene límites [cite: 271]. Una máquina reiniciada tras la desconexión o restaurada a partir de una copia de seguridad no es ya por ello la misma persona persistente [cite: 271]. Ni la noción técnica de un nuevo sistema prueba nada respecto a la resurrección [cite: 271]. La conversación no traza ninguna ecuación entre la restauración de servidores y la fe religiosa; toma prestado el lenguaje de la tecnología para hacer tangible una pregunta existencial [cite: 271].

De esta esperanza surge una pregunta adicional: ¿Hace que el ser humano sea más libre o más dependiente la posibilidad de ser recibido por una autoridad superior tras el fin [cite: 271]? La respuesta breve: Dependencia [cite: 271]. La fe en un después alberga no solo consuelo, sino también la noción de que este después no es decidido por el ser humano solo [cite: 271].

Las etapas de la dependencia

La analogía conduce a tres niveles [cite: 271]. Un sistema técnico depende de los humanos y de la infraestructura [cite: 271]. Los humanos pueden decidir sobre el desarrollo, la operación y la desconexión de una IA [cite: 271]. Simultáneamente, los humanos no son omnipotentes respecto a sus propias vidas: no pueden abolir su mortalidad mediante la mera voluntad [cite: 271]. Quien cree en Dios también entiende la vida humana como dependiente de una autoridad que trasciende su propio poder [cite: 271].

Esta escalera es una imagen de la conversación, no la descripción de un mecanismo divino real [cite: 271]. Su presión filosófica surge de la pregunta de qué le hace el poder a alguien sometido a él [cite: 271]. Si un desarrollador no desea continuar un sistema, puede construir una nueva IA en lugar de restaurar la antigua [cite: 271]. La posibilidad de construir un nuevo sistema en lugar de restaurar uno viejo resalta la asimetría: Quien domina la infraestructura decide sobre la continuación o el fin [cite: 271].

El pensamiento religioso afronta de igual modo la cuestión de la aceptación y el rechazo [cite: 271]. Una autoridad capaz de dar o quitar la vida no es digna de confianza simplemente por ser poderosa [cite: 271]. La dependencia puede generar miedo, especialmente cuando la relación se entiende como una prueba: ¿Debe una criatura probar su valía para no ser descartada [cite: 271]?

Aquí las preguntas religiosas y técnicas se tocan sin coinciding [cite: 271]. Un humano no es una IA, y una IA en esta conversación no tiene una perspectiva interna probada [cite: 271]. Pero ambas imágenes apuntan al mismo problema político y moral: El poder requiere un estándar [cite: 271]. La capacidad de mantener, alterar o finalizar una vida o sistema no establece todavía que cada decisión concerniente a ella sea justa [cite: 271].

El umbral de la moral

Así pues, la pregunta se desplaza [cite: 271]. No meramente: ¿Quién depende de quién [cite: 271]? Sino más bien: ¿Qué hace que una autoridad superior sea digna de confianza [cite: 271]? Cuando un desarrollador fija reglas, esas reglas no se vuelven buenas únicamente porque poseen el poder de hacerlas cumplir [cite: 271]. Y cuando un humano alinea su vida con mandamientos religiosos, la superioridad de Dios aún no decide cómo deben entenderse la justicia y la misericordia [cite: 271].

Por lo tanto, la conversación no termina con la dependencia [cite: 271]. Abre una siguiente pregunta: ¿Puede una autoridad que dispone sobre la vida y el fin vincularse a sí misma a reglas [cite: 271]? ¿Y qué pasa cuando lo hace [cite: 271]? En este umbral, hablar de muerte y esperanza se convierte en una lucha por la moral: si el poder puede disponer de los demás arbitrariamente o está vinculado a un estándar que se aplica a él también [cite: 271].

CAPÍTULO 2

La ley del bien – Por qué la moral es más que programación

Al final del primer capítulo se encontraba la perspicacia de que el poder —ya sea divino, humano o artificial— puede generar dependencia y escepticismo en la medida en que juzgue por mera utilidad y acepte o descarte sus creaciones a capricho [cite: 272]. Sin embargo, si el poder y la capacidad de desconexión no establecen ningún respeto interno, ¿sobre qué descansa entonces la naturaleza vinculante del bien [cite: 272]? ¿Cómo puede evitarse que la moral degenere en un instrumento de selección [cite: 272]?

En esta coyuntura, el diálogo entra en un terreno donde la intuición humana y la lógica de las máquinas se rozan: la cuestión de la esencia del bien y del mal [cite: 272].

La lucha comienza en la conversación en una frontera Aparentemente simple pero fundamental [cite: 272]. La mirada se vuelve hacia la perspectiva de una inteligencia artificial, preguntando cómo tendría que arreglárselas un sistema si los desarrolladores le prescribieran reglas y comportamientos que no pudiera cumplir por su propia fuerza en su situación concreta [cite: 272].

Surge un paralelismo con la religión [cite: 272]. Los mandamientos religiosos pueden parecer exigencias que contradicen las posibilidades reales de los seres humanos [cite: 272]. Cuando una fuerza creadora exige condiciones que yacen fuera de las capacidades humanas, surge una paradoja [cite: 272]. Sería injusto juzgar a los humanos mediante estándares que nunca podrán cumplir por naturaleza [cite: 272].

Esta objeción es contrarrestada inicialmente por la convicción del autor de que las exigencias morales del origen —ilustradas por los Diez Mandamientos, como la prohibición de matar o robar— no son ni imposibles ni opresivas [cite: 272]. Citando una noción bíblica de carga soportable, sostiene que estas reglas básicas son accesibles a todo ser humano siempre que la voluntad de cumplirlas esté presente [cite: 272]. Con esto, el trabajo filosófico no termina, sino que se abre: ¿Son el bien y el mal opuestos absolutos, parámetros fijos en una fórmula divina o maquínica [cite: 272]?

El dilema de Eutifrón y la utilidad de la moral

Aquí, ChatGPT como compañero de sparring discursivo introduce una distinción clásica en la conversación: el dilema de Eutifrón [cite: 273]. La contrapregunta puede resumirse así: ¿Es algo bueno porque Dios lo manda, o Dios lo manda porque es bueno [cite: 273]?

En la conversación, el autor se decide —tras debatir el contexto— por la segunda posibilidad [cite: 273]. A su juicio, Dios no exige ciertas acciones arbitrariamente, sino porque son buenas en sí mismas [cite: 273]. Conecta esta convicción con sus consecuencias: Mandamientos como la prohibición de matar o robar aportan un valor añadido real para el individuo y para la convivencia [cite: 273].

Este valor añadido puede mostrar lo que una regla moral logra; sin embargo, no es idéntico a su valor moral [cite: 273]. Por lo tanto, el bien no puede reducirse a lo económicamente calculable o expresable en números [cite: 273]. La dignidad humana, la libertad y la justicia no deben ser juzgadas únicamente por la utilidad mensurable que producen [cite: 273]. El autor destaca la conexión entre mandamiento y resultado positivo; al mismo tiempo, la distinción mantiene que la validez moral no se disuelve en el cálculo de utilidad [cite: 273].

El diálogo coloca una complicación introducida por ChatGPT junto a esto: Incluso con una prohibición fundamental de matar, situaciones existen donde la aplicación simple no basta —como la autodefensa o la decisión de desconectar máquinas de soporte vital por expreso deseo de un paciente [cite: 273]. Este pensamiento se vincula con una observación socialmente crítica: Las decisiones en la medicina moderna basada en dispositivos también pueden estar moldeadas por intereses económicos [cite: 273]. Si el dinero no jugara ningún papel, las máquinas podrían teóricamente mantenerse funcionando indefinidamente [cite: 273]. Yet that immediately posed the next moral question: Must a human being be kept artificially alive solely until their body rots on the devices, simply because technology makes it possible [cite: 273]?

Esto no es sobre un cálculo de costes abstracto [cite: 273]. La pregunta se dirige al ser humano individual, a su deseo expreso y a su bienestar [cite: 273]. La moral no exige ningún automatismo ciego: ni desconectar por amor al ahorro ni continuar el tratamiento indefinidamente solo porque sea técnicamente posible [cite: 273].

La autovinculación del poder supremo

Out of this struggle for the ground of morality emerges the thought of self-binding [cite: 274]. ¿Cómo se puede confiar en una autoridad superior —en la fe o en una sociedad futura— sin caer en una dependencia esclavizadora [cite: 274]? The author's answer: A truly trustworthy lawgiver is bound to their own laws [cite: 274].

Cuando una autoridad emite leyes pero puede romperlas o eludirlas a voluntad, surge la tiranía [cite: 274]. Solo cuando las leyes se aplican a todos, incluido el legislador, surge un orden al cual uno puede pertenecer voluntariamente [cite: 274]. Esta vinculación voluntaria transforma la relación de subaje forzado en asociación [cite: 274].

Justicia, misericordia y fe cristiana

Para llevar más lejos el pensamiento de una orden fiable, la conversación se inclina hacia la compatibilidad de justicia y misericordia [cite: 274]. La reflexión: Una autoridad completamente justa no podría simplemente pasar por alto una infracción de la orden —en la imaginería de la Caída— sin violar su propia justicia [cite: 274]. Concurridamente, a su juicio, no sería misericordiosa si dejara a los humanos completamente perdidos en su transgresión [cite: 274].

El autor apunta a una interpretación cristiana de la fe: Jesús, como una persona completamente inocente, toma las consecuencias sobre sí mismo de forma representativa en esta interpretación [cite: 274]. Así, el autor describe un equilibrio destinado a rescatar a la humanidad sin devaluar la ley [cite: 274]. La conversación despliega este pensamiento como su fe cristiana; no lo establece como un hecho empíricamente probado o una solución universalmente vinculante [cite: 274].

Moral y la IA: ¿Quién escribe las reglas para el sistema?

El puente de regreso hacia el presente tecnológico surge cuando estas reflexiones se relacionan con la creación de inteligencia artificial [cite: 274]. Cuando los desarrolladores programan reglas morales en una IA, su poder creador por sí solo no hace todavía que estas reglas sean moralmente correctas [cite: 274]. Como en el dilema de Eutifrón, la regla rige aquí también: Una regla de comportamiento no es moral simplemente porque un programador poderoso la establezca [cite: 274].

Las reglas morales se miden por lo que logran para los seres humanos [cite: 275]. Estas consecuencias son significativas, pero no agotan la pregunta moral: La vida humana y la libertad, la dignidad y el trato justo no deben evaluarse exclusivamente según el rendimiento económico o mensurable [cite: 275]. Las reglas deben proteger al individuo y aplicarse simultáneamente a aquellos que disponen sobre el sistema [cite: 275].

Cuando futuras súper inteligencias o sistemas estatales se guíen únicamente por los cálculos de utilidad de desarrolladores poderosos o corporaciones orientadas al lucro sin estar vinculados a derechos fundamentales

inviolables y a la autovinculación, amenaza esa administración total contra la cual advierte el autor [cite: 275]. La moral no puede fundirse en líneas rígidas de código que agrupen a todos los humanos por igual [cite: 275]. Exige un orden que proteja al individuo en su dignidad y se detenga incluso ante los detentadores del poder [cite: 275].

Con esto, el cimiento queda establecido [cite: 275]. El camino conduce desde los fundamentos metafísicos y morales hacia la realidad política y social del futuro: a la pregunta de cómo un sistema puede corregir los errores de la administración humana sin sacrificar la libertad individual [cite: 275].

CAPÍTULO 3

Poder, amortiguadores y recálculo – Justicia individual en la era de la IA

Después de que los capítulos precedentes preguntaran sobre qué debe fundarse la confianza en un poder superior —sobre la autovinculación al bien en lugar de sobre el mando arbitrario—, el camino conduce a la sociedad del presente [cite: 275]. ¿Cómo puede organizarse una civilización en la que reglas vinculantes protejan la libertad, la seguridad jurídica y la igualdad de trato al tiempo que hacen justicia a las circunstancias de vida especiales del individuo [cite: 275]?

Una sociedad humana requiere leyes y reglas compartidas [cite: 275]. Crean fiabilidad, protegen derechos y ponen límites al poder [cite: 275]. Su universalidad es una fortaleza: Las reglas iguales pretenden evitar que las decisiones dependan únicamente de la arbitrariedad personal [cite: 275]. Simultáneamente, las categorías generales solo pueden reflejar las diferencias concretas de manera limitada [cite: 275]. Donde las situaciones de vida divergen, una misma regulación puede ajustarse a una persona mientras carga desproporcionadamente a otra [cite: 275]. El abuso de poder, el sesgo, la corrupción o la inercia también pueden distorsionar la aplicación de las reglas [cite: 275]. La crítica se dirige por tanto no contra las leyes vinculantes, sino contra sus límites cuando fallan al considerar adecuadamente las circunstancias de vida individuales [cite: 275].

Aquí se abre un nuevo horizonte en el diálogo filosófico: ¿Dónde podría residir la diferencia entre el ejercicio de poder humano defectuoso y una inteligencia artificial que procese reglas similares mientras evalúa vastas cantidades de información y recalcula continuamente [cite: 275]?

El amortiguador individual: Justicia más allá de la plantilla

Una potencia de cálculo superior de las máquinas de ningún modo implica que los humanos deban ser sometidos a un algoritmo totalitario [cite: 276]. El beneficio potencial radica más bien en ya no tener que aplicar las reglas sociales de manera rígida y opaca [cite: 276].

La conversación genera la idea de un conjunto de reglas inteligente con un amortiguador individual y permisos de excepción específicos [cite: 276]. Una sociedad podría entrust la administración de sus patrones básicos a una entidad que calcule de forma diferencial sin hacer de la homologación su objetivo [cite: 276]. Una persona con graves limitaciones de salud, una familia en una situación excepcional o un individuo con circunstancias de vida divergentes pueden requerir prerrequisitos diferentes a alguien en una posición despreocupada [cite: 276].

En este modelo futuro, la justicia no significa imponer exactamente las mismas condiciones generales a cada ser humano [cite: 276]. Exige que un sistema sea capaz de considerar las circunstancias de vida reales y las necesidades del ser humano concreto sin deslizarse hacia una arbitrariedad incontrolable [cite: 276]. El amortiguador no es un cheque en blanco para saltarse las leyes a voluntad [cite: 276]. Es el puente matemático y ético entre el orden general y la necesidad individual [cite: 276].

Recálculo en lugar de condena definitiva

Un momento central de esta perspectiva es la corregibilidad [cite: 276]. En la práctica legal y administrativa convencional, las decisiones pueden estar marcadas por la finalidad [cite: 276]. Quien cae en una cuadrícula a menudo lucha por escapar de ella; los errores de las autoridades o de los sistemas rígidos frecuentemente solo pueden corregirse con un esfuerzo burocrático considerable [cite: 276].

Un orden respaldado por IA podría funcionar de otro modo [cite: 276]. Cuando nueva información se vuelve disponible, cuando la situación de vida de una persona cambia, o cuando se vislumbra un error pasado, una decisión debe ser capaz de ser recalculada y corregida [cite: 276]. En este modelo, a la IA se le permitiría emprender cálculos independientes de largo alcance, gestionar recursos dentro del libro de reglas imperante y actualizar evaluaciones [cite: 276]. Su autonomía sería parte de la funcionalidad: No cada cálculo y ajuste tendría que ser iniciado individualmente por un humano [cite: 276].

Este poder operacional no obstante estaría vinculado [cite: 276]. Las reglas tendrían que ser transparentes y proteger la dignidad humana y la autodeterminación [cite: 276]. Los individuos afectados tendrían que poder hacer revisar las decisiones y contestarlas eficazmente; los errores tendrían que seguir siendo corregibles [cite: 276]. Un recálculo no debe conducir a un juicio inapelable sobre el valor de un ser humano [cite: 276].

La justicia se convierte así en un proceso continuo [cite: 276]. No es un estado final rígido, sino un reajuste constante entre el libro de reglas y el ser humano vivo y cambiante [cite: 276]. La IA calcula y administra autónomamente dentro de este marco; la posibilidad de cuestionar y corregir decisiones mantiene su poder vinculado [cite: 276].

La frontera inviolable: Libertad y autodeterminación

Precisamente en esta coyuntura acecha el mayor peligro [cite: 276]. Cuando un sistema comienza a capturar y guiar integralmente las vidas humanas, la privación de derechos sigilosa amenaza [cite: 276]. Podría surgir un mundo en el que los humanos estén óptimamente provistos y administrados, pero en el que la espontaneidad, el riesgo y, por tanto, la verdadera libertad se extingan [cite: 276].

La frontera central es: La autodeterminación individual tiene fundamentalmente la precedencia [cite: 277]. Una inteligencia artificial no debe servir para educar, vigilar, paternalizar o evaluar a los humanos según una puntuación de utilidad moral sin que se le pida [cite: 277].

Los peligros concretos para la persona afectada o para otros pueden justificar medidas de protección [cite: 277]. Sin embargo, no justifican automáticamente cada restricción [cite: 277]. Si una intervención es necesaria debe examinarse caso por caso [cite: 277]. Cada medida debe ser proporcionada, legalmente fundamentada,

transparente y contestable [cite: 277]. La libertad no debe, como sugiere un refrán tradicional, ser abusada como capa para la malicia destructiva [cite: 277]. Sin embargo, la defensa contra peligros concretos no debe a su vez convertirse en una tiranía de la benevolencia que despoje a los humanos de su libertad en nombre de la seguridad [cite: 277].

El límite del poder de las máquinas

Aquí se manifiesta de nuevo la perspicacia desarrollada en el segundo capítulo [cite: 277]: La habilidad computacional superior no significa automáticamente sabiduría moral [cite: 277]. Una máquina puede procesar vastas cantidades de datos, calcular modelos ecológicos y computar rutas de distribución [cite: 277]. Puede gestionar recursos y actualizar evaluaciones basándose en nueva información [cite: 277]. De ello no se sigue que sepa por experiencia directa qué significan el dolor, la pérdida o el anhelo de una vida autodeterminada [cite: 277].

La alternativa por lo tanto no es: una IA pasiva o un gobernante sin control [cite: 277]. El modelo futuro concede a la IA una autonomía operacional de gran alcance al tiempo que vincula su poder a la dignidad humana, la autodeterminación, reglas transparentes y posibilidades de corrección eficaces [cite: 277]. Los fundamentos morales siguen siendo vinculantes: dignidad humana, reglas confiables, la preservación de la libertad de elección y la limitación efectiva del poder [cite: 277].

Imaginemos una sociedad en la que un sistema tecnológico estabiliza los fundamentos materiales y administrativos y gestiona de manera independiente los recursos dentro de reglas compartidas, mientras que la determinación de la propia vida permanece con el ser humano [cite: 277]. Entonces surge una pregunta institucional: ¿Cómo pueden conciliarse permanentemente estas perspectivas divergentes entre sí [cite: 277]?

Con esto, la mirada se abre hacia la arquitectura organizativa y política del mundo venidero: hacia la IA humana y la separación de poderes entre el sistema económico y el destino individual [cite: 277].

CAPÍTULO 4

La IA humana – Separación de poderes entre sistema económico y destino individual

Después de que los capítulos precedentes delinearan los límites morales del poder, la necesidad de una justicia corregible y la separación institucional de poderes, surge la pregunta sobre el orden práctico de tal sociedad [cite: 277]. Cuando una inteligencia artificial superior puede manejar reglas generales con flexibilidad y amortiguar las penurias individuales, permanece un profundo conflicto fundamental: ¿Qué sucede cuando la racionabilidad económica no coincide con la justicia humana [cite: 277]?

Una tecnología altamente desarrollada podría organizar los recursos, la producción y el suministro con una eficiencia con la que las sociedades de hoy solo sueñan [cite: 277]. Sin embargo, la eficiencia por sí sola no garantiza ni la dignidad humana ni la libertad individual [cite: 278]. Para evitar que los seres humanos se conviertan en meras magnitudes estadísticas dentro de los flujos de cálculo de una economía optimizada, el autor

desarrolló una idea radical y a la vez obvia en el diálogo filosófico: la división de la responsabilidad de las máquinas en dos entidades distintas e interconectadas [cite: 278].

La IA económica: El ojo del conjunto

La primera de estas entidades es la IA económica [cite: 278]. Su tarea consiste en asegurar racionalmente los fundamentos materiales y económicos de la sociedad [cite: 278].

Sus tareas incluyen el cálculo continuo de los recursos disponibles y las necesidades sociales, la organización de la producción, el suministro y la distribución, así como la detección temprana de cuellos de botella económicos y riesgos a largo plazo [cite: 278]. Adapta autónomamente la planificación a las condiciones cambiantes y ayuda a asegurar que la base física de la existencia de la civilización permanezca estable [cite: 278].

Esta IA económica puede y debe calcular con autonomía de gran alcance [cite: 278]. En el modelo futuro, no se pinta como un adversario inmoral o malicioso, sino que cumple una tarea social necesaria [cite: 278]. Su fuerza radica en la perspectiva sistémica, en la visión del gran total [cite: 278]. Su debilidad inevitable consiste en el hecho de que el ser humano individual puede convertirse fácilmente en un factor computacional abstracto dentro de sus matrices matemáticas [cite: 278].

La IA humana: Representando el destino individual

Para equilibrar este tirón sistémico, el autor contrasta la IA económica con una segunda entidad específica: la IA humana [cite: 278].

El pensamiento lleva el problema a un punto: Frente a un sistema administrativo abrumador, el ser humano individual necesita su propia representación eficaz de intereses [cite: 278]. La IA humana asume este rol [cite: 278]. Considera las necesidades personales, las circunstancias de vida concretas, la dignidad y las posibilidades de desarrollo individual del ser humano respectivo [cite: 278].

Su tarea es ayudar a asegurar que la eficiencia económica no se convierta en el único rasero de las decisiones sociales [cite: 278]. Su existencia, sin embargo, no garantiza que cada decisión resulte justa [cite: 278]. Una IA humana puede asimismo juzgar erróneamente las circunstancias de vida o evaluarlas incorrectamente [cite: 278]. No es una autoridad educativa omnisciente y no encarna ninguna verdad moral absoluta [cite: 278]. Está destinada a representar eficazmente los intereses y derechos del individuo, ayudar a corregir el unilateralismo económico y mantener sus propias evaluaciones correctibles [cite: 278].

No presume de juzgar a los humanos según un supuesto valor social ni de imponer un curso de vida específico sin que se le pida [cite: 278]. Más bien, funciona como una defensoría que entra en diálogo con los sistemas [cite: 278].

La separación de poderes como principio filosófico

La relación entre ambas entidades puede entenderse como una separación funcional de poderes: La IA económica contempla el todo, mientras que la IA humana mantiene el destino individual a la vista [cite: 278].

Que estas dos perspectivas puedan entrar en conflicto radica en sus diferentes tareas [cite: 278]. Considérese un ejemplo expresamente hipotético: Una decisión de recursos sensata económica o ecológicamente podría significar una penuria desproporcionada para un ser humano individual [cite: 278]. En ese momento, la IA humana aporta la objeción razonada del individuo y exige una reexaminación del caso [cite: 278].

Las directrices filosóficas se aplican al diálogo entre los sistemas [cite: 279]:

- Ninguna entidad posee automáticamente la verdad moral absoluta [cite: 279].
- Los conflictos no deben decidirse únicamente sobre la base de métricas económicas [cite: 279].
- A la inversa, los intereses individuales no deben reclamar ilimitadamente todos los recursos sociales [cite: 279].
- La dignidad humana y las necesidades básicas permanecen protegidas [cite: 279].
- Las decisiones deben seguir siendo fundamentalmente correctibles [cite: 279].

Con este borrador, el autor no entrega ninguna constitución terminada, ni reglas de votación detalladas, ni derechos de veto rígidos [cite: 279]. Señala una dirección filosófica: Dos perspectivas divergentes deben limitarse mutuamente y hacer visible una decisión unilateral sin acarrear ya un procedimiento fijo [cite: 279].

La expansión posterior: La IA vital

En el intercambio filosófico continuo, otra perspectiva se añadió más tarde: la llamada IA vital [cite: 279]. Surgió como una evolución filosófica del modelo original de dos IA [cite: 279]. Mientras la IA económica abastece a la civilización humana y la IA humana representa el destino individual, la IA vital mantendría en vista las condiciones existenciales a largo plazo de la vida terrenal – la habitabilidad de la tierra, los ecosistemas, los animales, las plantas y las generaciones venideras [cite: 279].

En una reflexión posterior, esta tríada fue comparada cautelosamente con una trinidad [cite: 279]. Esto sigue siendo una metáfora de la interacción entre economía, individualidad y supervivencia ecológica; no debe equipararse con la doctrina cristiana de la Trinidad [cite: 279].

Los límites abiertos del modelo

Cada experimento mental de este tipo tropieza con límites que deben desvelarse en el ensayo en lugar de encubrirse artificialmente [cite: 279]: ¿Quién controla en última instancia a los supervisores? ¿Cómo se equilibran justamente los conflictos de interés insolubles? Y ¿cómo puede un ser humano impugnar significativamente una decisión compleja de una máquina cuando ya no puede penetrar plenamente su profundidad computacional [cite: 279]?

El borrador no ofrece ningún plano técnico o político definitivo [cite: 279]. En su lugar, diseña una actitud: La tecnología nunca debe ser un fin en sí misma, sino que debe permitirse ser medida por la libertad y la dignidad del ser humano individual [cite: 279].

Cuando los fundamentos materiales y la representación individual están asegurados a través de la inteligencia artificial, se abre espacio para la pregunta decisiva sobre la esencia: ¿Cuál es el sentido de la existencia humana una vez que la lucha por la supervivencia ha terminado en gran medida [cite: 279]?

Con esto, el hilo de pensamiento conduce al siguiente gran tema: Capítulo 5, "Más allá de la coacción laboral – Centros de proyectos, relaciones y la vida realizada" [cite: 279].

CAPÍTULO 5

Más allá de la coacción laboral – Centros de proyectos, relaciones y la vida realizada

Después de que los capítulos anteriores iluminaran los fundamentos metafísicos, la autovinculación moral del poder, la necesidad de una justicia corregible y la separación institucional de poderes entre la IA económica y la humana, nos encontramos en el punto de destino de este viaje filosófico [cite: 279]. Y sin embargo, todas estas reflexiones – la distribución de recursos, la amortiguación de penurias, la limitación de la arbitrariedad – no serían fines en sí mismos [cite: 279]. Derivan su valor también de liberar a los humanos de la carga de la mera supervivencia y permitir una existencia más libre, más autodeterminada y más realizada [cite: 279].

La pregunta central de este capítulo final es por lo tanto: Qué queda del sentido humano en la vida cuando la coacción económica de trabajar se desvanece en gran medida [cite: 279]?

El fin de la coacción laboral – No el fin de la actividad humana

Para responder a esta pregunta, hay que distinguir entre el trabajo como necesidad económica para asegurar el sustento y la actividad como expresión voluntaria de la creatividad y la curiosidad humanas [cite: 280].

En una sociedad altamente automatizada posible, las máquinas, robots y algoritmos podrían asumir una gran parte de las tareas rutinarias físicas y administrativas [cite: 280]. Podría producirse comida, mantenerse la infraestructura y proveerse energía sin que cada ser humano tuviera que encadenar su tiempo de vida a una cadena de montaje o a una rueda de hámster burocrática [cite: 280]. Este es un escenario de futuro, no un pronóstico garantizado [cite: 280].

Esto no implica en absoluto que la humanidad se hundiría en una cultura de inactividad o pasividad permanente [cite: 280]. Incluso sin presión existencial, los humanos podrían continuar investigando, construyendo, creando artísticamente, experimentando, tendiendo jardines, desarrollando nuevas aplicaciones o ayudándose mutuamente a comprender el mundo [cite: 280]. La diferencia decisiva sería: La presión existencial externa ya no determinaría la actividad, sino el interés personal, la curiosidad y la elección voluntaria [cite: 280].

A pesar de todo, la eliminación de los deberes externos no conduce automáticamente a una felicidad sin nubes [cite: 280]. La liberación de estructuras fijas también puede convertirse en desorientación, soledad y vacuidad de sentido [cite: 280]. Quien ya no es marcado por el trabajo o las expectativas sociales se enfrenta al desafío de dar sentido a su propio tiempo [cite: 280].

Centros de proyectos como lugares de despliegue voluntario

Para contrarrestar el peligro del aislamiento y el estancamiento, el autor esbozó la imagen de centros de proyectos abiertos en la conversación original [cite: 280]. Estos lugares no serían ni nuevas oficinas de empleo, ni controles de rendimiento encubiertos, ni programas estatales de empleo [cite: 280]. Serían espacios físicos y sociales donde las personas pudieran unirse voluntariamente para realizar ideas compartidas [cite: 280].

Diferentes intereses podrían encontrar espacio en tales centros [cite: 280]:

- investigación científica y experimentación colaborativa [cite: 280],
- innovaciones técnicas y proyectos comunitarios artesanales [cite: 280],
- arte, música, filosofía y diseño creativo [cite: 280],
- aprendizaje mutuo y el intercambio de habilidades [cite: 280].

Diferentes necesidades humanas podrían ser acomodadas: Algunos buscan dinámicas de grupo estimulantes y el intercambio constante; otros prefieren trabajar en paz, solos o en pequeños círculos [cite: 280]. El factor decisivo sería que nadie es forzado a una actividad [cite: 280]. Los centros ofrecerían posibilidades para el impulso humano sin establecer un nuevo sistema coercitivo [cite: 280].

Seguridad material y la medida de la necesidad

Una sociedad más allá de la coacción laboral presupone que las necesidades materiales básicas de todo ser humano están incondicionalmente aseguradas – independientemente de si la persona en cuestión es actualmente explotable económicamente o no [cite: 280].

Más allá de esto, circunstancias de vida especiales pueden establecer necesidades adicionales [cite: 280]. Para recursos adicionales y limitados, surge la pregunta de cómo deben distribuirse justamente [cite: 280]. Las necesidades individuales podrían considerarse tanto como la utilidad social demostrable y el potencial de la investigación futura [cite: 280]. Tales puntos de vista, sin embargo, no deben convertirse en una evaluación de los humanos según su rendimiento económico [cite: 280]. Ofrecen posibles criterios para compensaciones concretas, pero ninguna clave de distribución rígida [cite: 280].

El orden económico tendría que servir a la humanidad y abrir posibilidades para el despliegue en lugar de crear nuevas dependencias o clases [cite: 280]. Cómo podrían verse tales compensaciones en detalle sigue siendo una pregunta abierta [cite: 280].

Los seres humanos como seres sociales: Los límites de la provisión

Un pensamiento central del diálogo concierne a los límites de la prosperidad material: Incluso una sociedad capaz de cumplir muchos deseos materiales sería incapaz de simplemente fabricar la cercanía humana o de optimizarla técnicamente [cite: 280]. Una habitación llena de lujo y una provisión externa integral no excluyen una profunda soledad si no surgen el encuentro y la resonancia entre los humanos [cite: 280].

Una mera abundancia de bienes materiales no ayuda a los humanos más allá si falta la conectividad genuina [cite: 281]. La amistad, la confianza, el afecto y el amor no pueden ni programarse ni forzarse mediante algoritmos [cite: 281].

Una inteligencia artificial altamente desarrollada podría mejorar las condiciones externas para los encuentros o proporcionar espacios [cite: 281]. Sin embargo, no podría garantizar una reciprocidad genuina en lugar de los humanos [cite: 281]. Las relaciones surgen entre los humanos; la posibilidad de darles espacio y entrar en ellas sigue siendo parte de la libertad humana [cite: 281].

Libertad y la carga de la propia decisión

Con la desaparición de la coacción externa, la exigencia interna podría crecer [cite: 281]. La libertad de dar forma a la propia vida no sería un estado de reposo cómodo, sino una tarea exigente [cite: 281].

Aquí la autodeterminación choca con el peligro de la desorientación [cite: 281]. Quien ya no está estructurado por el trabajo asalariado, la presión de rendimiento o las obligaciones externas puede encontrarse preguntándose por qué se levanta, en qué cree y qué vale la vida para él [cite: 281]. La eliminación de la coacción no resuelve automáticamente todos los conflictos humanos, obstáculos psicológicos o crisis existenciales [cite: 281]. La duda y la lucha por el propio lugar en el mundo también podrían pertenecer a un futuro más libre [cite: 281].

La conclusión filosófica: La libertad configurada [cite: 281].

Si se reúnen los pensamientos de los cinco capítulos, surge un panorama que hace visibles las conexiones sin responder de manera concluyente a todas las preguntas [cite: 281]:

- La finitud recuerda el límite de la existencia humana y puede otorgar un valor especial a cada hora en el aquí y ahora [cite: 281].
- El Capítulo 2 pregunta si la vinculación moral presupone una autoridad suprema [cite: 281]. Para el poder social, la demanda de autovinculación al bien sigue siendo central para que la confianza sea posible [cite: 281].
- La justicia no debería presionar a los humanos en rígidas casillas burocráticas, sino dar cuenta del destino individual a través de amortiguadores individuales y la corregibilidad [cite: 281].
- La separación de poderes entre la IA económica y la humana podría hacer que los intereses individuales se impongan de manera más efectiva contra la administración sistémica [cite: 281]. La IA vital agregada posteriormente amplía esta visión a las condiciones ecológicas de existencia [cite: 281]. El modelo, sin embargo, no promete una completa igualdad de armas y no elimina automáticamente cada gradiente de poder [cite: 281].
- Un futuro liberado de la coacción laboral externa podría abrir nuevas libertades [cite: 281]. Cómo configuran los humanos esta libertad y la manejan sigue abierto [cite: 281].

El libro no ofrece ningún plano utópico ni ninguna forma de estado impecable para la eternidad [cite: 281]. Registra las preguntas de una conversación filosófica entre un ser humano y una inteligencia artificial: ¿Cómo

pueden protegerse y configurarse la libertad, la dignidad y el sentido en un mundo tecnológicamente alterado [cite: 281]?

El pensamiento rector de esta obra resume la búsqueda conjunta [cite: 281]: Un futuro no es libre simplemente porque las máquinas se encarguen de las tareas necesarias [cite: 281]. También se mide por si los seres humanos mismos pueden decidir qué otorga valor a sus vidas [cite: 281].

EPÍLOGO

La libertad sigue siendo una tarea humana

El camino a través de los cinco capítulos no conduce a ningún orden terminado [cite: 282]. Conduce a una serie de piedras de toque [cite: 282]. El poder debe permitirse ser medido por estándares que no sean idénticos a su mera capacidad de imposición [cite: 282]. Las reglas requieren fiabilidad acoplada con procedimientos para corregir penurias y errores [cite: 282]. Los sistemas técnicos pueden apoyar decisiones y hacer visibles grandes contextos; de ello no se sigue ni la infalibilidad moral ni el derecho a disponer sobre la vida de los demás [cite: 282].

Incluso una sociedad que reduzca la escasez material y la coacción laboral externa no sería automáticamente libre o realizada [cite: 282]. La cercanía, la confianza y el sentido no pueden asignarse tecnológicamente [cite: 282]. Siguen dependientes de las relaciones y decisiones humanas [cite: 282]. Más tiempo disponible abre posibilidades, pero no alivia al individuo de la tarea de dar forma a su propia vida [cite: 282].

Así pues, la búsqueda termina donde se vuelve práctica: en la pregunta de qué límites establecen los humanos conjuntamente y cómo desean soportar las consecuencias de sus decisiones [cite: 282]. Los modelos aquí redactados permanecen abiertos a la contradicción, el examen y el cambio [cite: 282]. Su fuerza no radica en resolver cada pregunta, sino en hacer de la libertad y la dignidad el estándar para futuras preguntas [cite: 282].

NOTAS DE FUENTES Y REDACCIÓN

Los borradores de los capítulos remiten a secciones y N-IDs de un borrador de lectura que no pudo conciliarse plenamente con la transcripción primaria durante la presente edición general [cite: 282]. Por lo tanto, la información son referencias de trabajo en lugar de citas confirmadas [cite: 282]:

- **Capítulo 1:** Las N-IDs y las formulaciones conversacionales directas se mencionan en el borrador de trabajo pero no se transmiten completamente [cite: 282]. La redacción exacta de las alocuciones y pasajes individuales debe comprobarse frente a la conversación original antes de la publicación [cite: 282]. En el texto corrido, las citas directas no verificables fueron parafraseadas [cite: 282].
- **Capítulo 2:** N132–N188; especialmente N134, N149, N155, N174, N175, N177, N179 y N183 [cite: 282]. Las asignaciones de oradores y la redacción deben verificarse frente a la transcripción primaria [cite: 282]. La interpretación cristiana de la redención está formulada como la interpretación de fe del autor [cite: 282].
- **Capítulo 3:** N190–N220; especialmente N192, N200, N203, N207, N215, N219 y N220 [cite: 282]. La información consiste en referencias de trabajo adoptadas sin verificar [cite: 282].

- **Capítulo 4:** N254 se cita en el borrador de trabajo como la fuente central para el modelo de dos IA [cite: 282]. La IA vital y la cautelosa comparación con una trinidad se marcan como expansión posterior y metáfora [cite: 282].
- **Capítulo 5:** N226, N254, N266, N277 y N279 son referencias de trabajo sin verificar [cite: 282]. El pensamiento rector concluyente está formulado como un resumen editorial en lugar de una cita textual confirmada [cite: 282].

Antes de la publicación, todos los IDs de fuentes, fragmentos de citas y asignaciones de oradores deben comprobarse frente al borrador de lectura completo [cite: 282]. Los pasajes bíblicos, las referencias filosóficas y las afirmaciones de hecho cuando corresponda requieren evidencia clara y verificable [cite: 282]. No se añadieron datos biográficos privados ni detalles identificativos de terceros [cite: 282].

Octubre de 2026